

Manual de Metodologia: Inversão Geofísica Probabilística e Aprendizagem Automática na Prospeção de Minerais Críticos

1. Enquadramento Técnico e a Ineficiência do Determinismo na Prospeção Profunda

A aceleração da transição energética global e o declínio acentuado dos depósitos minerais superficiais impõem um imperativo estratégico à indústria extrativa: a prospeção eficiente de corpos mineralizados ocultos a grandes profundidades (de várias centenas de metros a mais de um quilómetro). Historicamente, a geofísica de exploração tem confiado em inversões determinísticas baseadas num modelo único do subsolo. Contudo, perante a escassez de dados diretos e a complexidade não-linear da geologia profunda, o paradigma determinístico revelou-se estruturalmente inadequado. A incapacidade de quantificar a incerteza estatística e a imposição de restrições matemáticas artificiais conduzem à alocação ineficiente de capital em campanhas de perfuração de elevado risco. Para reverter a queda acentuada nas taxas de descoberta de minerais críticos (como o cobre, níquel, cobalto e elementos do grupo da platina), torna-se imperativo migrar do determinismo clássico para um paradigma probabilístico rigoroso. Esta abordagem, ancorada no cálculo Bayesiano e na modelação estocástica por *ensembles*, permite caracterizar exaustivamente o espaço de soluções equiprováveis e orientar a tomada de decisão em engenharia de exploração.

1.1 O Problema Fundamental da Inversão Geofísica e as Limitações do Determinismo Tradicional

A determinação da distribuição espacial de propriedades físicas no subsolo (como condutividade elétrica, densidade ou suscetibilidade magnética) a partir de medições de campo à superfície constitui um problema inverso mal posto (*ill-posed inverse problem*). Enquanto a modelação direta (*forward modeling*) calcula de forma unívoca e determinística a resposta de campo observável $\mathbf{d}$ a partir de um conjunto de parâmetros do subsolo $\mathbf{m}$ através de leis físicas fundamentais ($\mathbf{d} = g(\mathbf{m})$), a inversão direta de equações não-lineares sofre de uma severa não-unicidade (*non-uniqueness*). Infinitas configurações $\mathbf{D}$ de propriedades físicas no subsolo geram exatamente os mesmos dados geofísicos à superfície. A formulação Bayesiana rigorosa do problema inverso expressa-se como: $P(\mathbf{m}|\mathbf{d}) = \frac{P(\mathbf{d}|\mathbf{m}) P(\mathbf{m})}{P(\mathbf{d})}$ Onde $P(\mathbf{m}|\mathbf{d})$ representa a distribuição de probabilidade *a posteriori* dos parâmetros do modelo dado o conjunto de dados observados $\mathbf{d}$, $P(\mathbf{d}|\mathbf{m})$ é a função de verosimilhança (*likelihood*), e $P(\mathbf{m})$ é a distribuição *a priori* que codifica as restrições geológicas conhecidas. Na prática geofísica tradicional, contudo, o cálculo da distribuição *a posteriori* completa é descartado devido à sua complexidade computacional. Em seu lugar, aplica-se uma otimização determinística pontual baseada na minimização de uma função de custo regularizada: $\Phi(\mathbf{m}) = \|\mathbf{d} - g(\mathbf{m})\|_2^2 + \lambda \mathbf{R}(\mathbf{m})$ Onde $\|\mathbf{d} - g(\mathbf{m})\|_2^2$ quantifica o desajuste dos dados (*data misfit*), $\mathbf{R}$ representa um operador de suavização espacial (habitualmente regularização L_2 Tikhonov ou L_1 de variação total) e λ é o parâmetro de regularização. Esta abordagem tradicional força o sistema a convergir para um único modelo suavizado. O impacto desta aproximação pode ser

comparado à tentativa de reconstruir uma imagem de alta resolução a partir de uma fotografia fora de foco: o processo de desfocagem (modelação direta) perde irreversivelmente as frequências espaciais elevadas. Tentar inverter deterministicamente essa imagem sem um enquadramento probabilístico obriga o algoritmo a preencher as lacunas com suavização contínua ou artefactos matemáticos não-físicos. As falhas operacionais inerentes ao determinismo tradicional resumem-se a duas dimensões críticas:

1. **Artefactos de Suavização Não-Físicos ("Alucinações do Modelo"):** Ao penalizar variações abruptas para estabilizar o problema inverso, a regularização matemática cria geometrias difusas que não existem na natureza. Na exploração de depósitos minerais, em que as fronteiras litológicas e as falhas tectónicas são descontinuidades discretas e nítidas, o modelo determinístico gera "alucinações" — como transições graduais de densidade ao longo de quilómetros ou geometrias anómalas e estruturalmente impossíveis (análogas a representações anatómicas incorretas geradas por inteligência artificial não condicionada).
 2. **Ilusão de Certeza Absoluta e Falsa Ancoragem:** O determinismo entrega à equipa técnica um único bloco tridimensional de valores, desprovido de barras de erro locais, covariâncias espaciais ou métricas de incerteza residual. Esta ausência de quantificação do risco induz a uma falsa ilusão de certeza, levando geólogos e executivos a planejar furos de sondagem dispendiosos com base no ponto central de anomalias suavizadas que podem ser meros artefactos da função de regularização.
- Eixo de Análise | Abordagem Determinística Tradicional | Abordagem Probabilística Baseada em Ensembles || ----- | ----- | ----- || **Tratamento da Unicidade** | Ignora a não-unicidade intrínseca; força uma solução única mediante aproximações de minimização pontual. | Aceita e quantifica a não-unicidade; mapeia o espaço de soluções equiprováveis $\mathbf{m}$ || **Regularização / Suavização** | Aplica penalizações matemáticas L_1/L_2 que geram gradientes contínuos e não-geológicos. | Substitui a suavização por restrições estocásticas baseadas em covariâncias espaciais por pacote sedimentar/litológico. || **Validação Geológica** | Gera estruturas suavizadas e fisicamente irrealistas ("alucinações" decorrentes da função de custo). | Modela hipóteses geológicas discretas e explícitas (elipsoides, camadas, estruturas) validadas contra dados de campo. || **Representação do Risco** | Nula; entrega um modelo estático sem intervalos de confiança nem variabilidade local de parâmetros. | Completa; fornece distribuições de probabilidade completas, mapas de erro estocástico e bandas de incerteza em n dimensões. |

1.2 Taxonomia da Incerteza Geocientífica: Incerteza Aleatória vs. Epistémica

A formulação de um modelo probabilístico rigoroso exige a decomposição formal e a categorização da incerteza que afeta a tomada de decisão na prospeção profunda. Nas geociências computacionais, a incerteza divide-se em duas categorias fundamentais:

- **Incerteza Aleatória (Aleatory / Stochastic Uncertainty):** Representa o ruído estocástico irreduzível intrínseco aos processos de medição física, à instrumentação de campo e à variabilidade de amostragem na recolha de dados do subsolo.
- **Erros Analíticos de Ensaio:** A discrepância estocástica observada entre dados obtidos por métodos portáteis de Fluorescência de Raios X (XRF) no terreno vs. Análises de laboratório via Espetrometria de Massa com Plasma Indutivamente Acoplado (ICP-MS).
- **Erros Operacionais de Geometria de Sondagem:** A incerteza angular acumulada nos instrumentos de desvio (*downhole survey*) que medem o azimuth e a inclinação

de um furo de sondagem a 1.000 metros de profundidade, resultando num desvio espacial em torno da trajetória teórica do furo.

- **Ruído de Aquisição Geofísica:** As variações na Relação Sinal-Ruído (SNR) induzidas por correntes telúricas, ruído eletromagnético cultural (linhas de alta tensão, infraestruturas) ou acoplamento capacitivo imperfeito dos sensores de campo.
- **Incerteza Epistémica (Epistemic / Structural Uncertainty):** Representa a limitação do conhecimento humano sobre o sistema geológico subjacente, traduzindo-se na coexistência de múltiplas hipóteses conceptuais e modelos estruturais concorrentes capazes de explicar os mesmos dados observados.
- **Continuidade Estrutural vs. Descontinuidade Tectónica:** A dúvida interpretativa se uma camada mineralizada se estende continuamente em profundidade ou se foi cortada e deslocada por uma falha cega não mapeada (alterando radicalmente a distribuição de probabilidade de presença do minério a oeste ou a leste do alinhamento).
- **Génese do Mecanismo de Deposição:** A coexistência de hipóteses concorrentes sobre se um condutor eletromagnético profundo corresponde a uma conduta magmática de sulfuretos maciços de Ni-Cu-PGE ou a uma camada intrusiva de grafite/pirrotite sedimentar não económica.

1.3 O Paradigma Multimodelo e a Mitigação do Anchoring Cognitivo

A psicologia cognitiva demonstra que geólogos e engenheiros de exploração estão sujeitos ao viés de ancoragem (*anchoring bias*): uma vez construído o primeiro modelo geológico tridimensional de um jazigo, a equipa técnica tende a interpretar todos os dados subsequentes de forma a confirmar esse modelo inicial. No determinismo tradicional, este viés é amplificado pela entrega de um único modelo "ótimo". Para mitigar radicalmente esta limitação, a metodologia desenvolvida por entidades inovadoras como a KoBold Metals substitui a procura do "modelo perfeito" pela formulação de um **Paradigma Multimodelo**. Todas as hipóteses geologicamente plausíveis formuladas por geólogos estruturais, geofísicos, cientistas de dados e técnicos de campo são formalizadas sob a forma de restrições matemáticas e integradas no processo de amostragem estocástica. No domínio da geoestatística clássica, o fluxo de trabalho assenta na construção de um variograma empírico único $\gamma(h)$, que descreve a semivariância espacial das propriedades em função da distância h . Em fases iniciais de exploração, contudo, a escassez de dados de sondagem torna a seleção de um único variograma arbitrária e cientificamente injustificada. A **Geoestatística Bayesiana** resolve esta lacuna ao tratar os parâmetros do variograma — o patamar (*sill* $C_0 + C$), o alcance (*range* a) e o efeito pepita (*nugget* C_0) — não como constantes fixas, mas como variáveis aleatórias governadas por distribuições *a priori* $P(\theta)$, onde $\theta = \{C_0, C, a\}$. À medida que novos dados de terreno $\mathbf{D}$ são assimilados, a distribuição *a priori* dos parâmetros geoestatísticos é atualizada via regra de Bayes para obter a distribuição *a posteriori* $P(\theta|\mathbf{D})$. A geração das realizações espaciais do subsolo não é feita a partir de um variograma fixo, mas sim integrando sobre todo o espaço de parâmetros geoestatísticos válidos. O fluxo de processamento Bayesiano para a geração do *ensemble* multimodelo é estruturado no seguinte pipeline computacional:

```
[Parâmetros a Priori  $P(\theta)$ ]  $\rightarrow$  [Dados Observados de Terreno  $\mathbf{D}$ ]  $\rightarrow$  [Atualização de Verosimilhança Bayesiana  $P(\mathbf{D}|\theta)$ ]
```

|



[Ensemble de Realizações Geológicas] ← [Simulação Condicional]
← [Parâmetros a Posteriori $P(\theta|D)$]
(Milhares de Grelhas 3D Equiprováveis) (Gaussian Sequencial /
Independente de
Indicadores)

Através do processo de simulação condicional (como a Simulação Sequencial Gaussiana ou a Simulação por Indicadores) executado sobre cada amostra da distribuição *a posteriori* $P(\boldsymbol{\theta}|\mathbf{D})$, geram-se milhares de realizações estocásticas do subsolo ($N > 1.000$). Este *ensemble* de realizações preserva a variabilidade espacial e garante que as incertezas aleatórias e epistêmicas sejam totalmente propagadas até às fases subsequentes de tomada de decisão. A quantificação rigorosa e sem filtros da incerteza geocientífica constitui a base matematicamente sólida sobre a qual assentam as metodologias avançadas de inversão geofísica probabilística e a criação de emuladores computacionais de alta performance.

2. Metodologia de Inversão Probabilística e Modelação de Ensembles Geofísicos

A implementação prática do cálculo probabilístico Bayesiano em geofísica esbarra historicamente na barreira da complexidade computacional. A amostragem de distribuições *a posteriori* de alta dimensão via métodos de Monte Carlo via Cadeias de Markov (MCMC) requer a execução de milhões de simulações diretas (*forward simulations*). O desenvolvimento de emuladores baseados em redes neuronais e Inteligência Artificial (*surrogate models*) permite ultrapassar esta barreira, acelerando o cálculo das equações da física geofísica sem perda de precisão e viabilizando a inversão estocástica em tempo útil.

2.1 Modelação Direta (Forward) e Criação de Emuladores/Modelos Surrogate via IA

A modelação direta consiste na resolução de equações diferenciais às derivadas parciais (EDPs) que regem os campos físicos (como as equações de Maxwell para o eletromagnetismo ou a equação de Poisson para a gravimetria) sobre uma malha discretizada $\mathbf{D}$ do subsolo. Embora seja um processo matematicamente bem posto e determinístico, a resolução numérica exata (via Métodos de Elementos Finitos - FEM ou Diferenças Finitas - FDM) de uma única malha complexa pode demorar minutos a horas. Em estratégias de amostragem probabilística que requerem 10^6 a 10^8 avaliações, a resolução direta tradicional é computacionalmente proibitiva. Nas décadas transcorridas desde os anos 1990, a indústria de exploração recorreu a aproximações analíticas altamente simplificadas, como o modelo de placas de Maxwell (*Maxwell plate modeling*). Contudo, a investigação detalhada (conforme demonstrado por Beth Reid e colaboradores) explicita as falhas físicas graves destas aproximações simplificadas:

- **Variação do Campo Primário:** O modelo de placas de Maxwell assume um campo magnético/eletromagnético primário uniforme sobre a superfície da placa, falhando drasticamente quando existem fortes gradientes do campo primário ao longo do corpo indutor.

- **Distorção das Correntes de Indução 2D/3D:** As equações simplificadas forçam as correntes induzidas a percorrerem trajetórias fechadas num plano bidimensional idealizado, ignorando a indução complexa tridimensional e o desvio de correntes (*current gathering*) entre o corpo condutor e a rocha encaixante.
 - **Interação com a Rocha Encaixante:** Ignoram o acoplamento galvânico e a condutividade da rocha hospedeira, conduzindo a estimativas erradas do produto condutividade-espessura (condutância) do alvo. Para superar estas limitações sem incorrer nos custos computacionais inviáveis do FEM/FDM $\mathcal{D}$, constroem-se **Modelos Surrogate baseados em Aprendizagem Profunda :**
1. **Geração do Conjunto de Treino Físico:** Executam-se dezenas de milhares de simulações diretas exatas ($\mathcal{D}$ FEM) cobrindo um espaço amostral de parâmetros de entrada $\mathbf{m}$ (geometrias, profundidades, condutividades, orientações).
 2. **Treino da Arquitetura Neuronal Emuladora:** Uma rede neuronal convolucional ou baseada em operadores de Fourier (*Fourier Neural Operators* - FNO) é treinada para mapear diretamente os parâmetros $\mathcal{D}$ do subsolo $\mathbf{m}$ na resposta do sensor à superfície $\mathbf{d}$.
 3. **Aceleração da Avaliação Directa:** O emulador neuronal treinado substitui o resolvidor de EDPs, executando a modelação direta em milissegundos. De acordo com os dados operacionais apresentados por Mfikeyi Makayi (TED Talk 2025), este avanço computacional permite prever e avaliar respostas geofísicas até **10.000 vezes mais rápido** do que os métodos convencionais de inversão física.
 4. **Cálculo da Verosimilhança Bayesiana:** O ganho computacional de $10.000\times$ permite calcular a função de verosimilhança $P(\mathbf{d}_{\text{obs}}|\mathbf{m})$ para milhões de configurações num esquema de amostragem estocástica em tempo real.
 5. **Filtragem e Extração de Ensembles:** Descartam-se os modelos incompatíveis com os dados medidos no terreno e retém-se o *ensemble* de realizações que satisfaz a distribuição *a posteriori* .

2.2 Discriminação Geométrica e Física em Métodos Eletromagnéticos no Domínio do Tempo (TDEM)

Na prospeção de depósitos de sulfuretos magmáticos de Níquel-Cobre-Elementos do Grupo da Platina (Ni-Cu-PGE), os levantamentos geofísicos Eletromagnéticos no Domínio do Tempo (TDEM) constituem o método primário de prospeção. A condutividade elétrica dos sulfuretos maciços (como a pentlandita e a calcopirita) pode ser até 10^9 vezes superior à da rocha encaixante silatada (silicatos/peridotitos). No entanto, a condutividade elétrica por si só é um discriminador ambíguo. Ambientes sedimentares onde os magmas intrudiram contêm frequentemente horizontes de grafite sedimentar e camadas de pirrotite, cujas respostas de condutividade se sobrepõem perfeitamente às assinaturas de condutividade do Ni-Cu-PGE. A resolução deste problema de ambiguidade física faz-se através da **discriminação geométrica e morfológica dos corpos condutores** ajustados no *ensemble* probabilístico. Modelando os condutores anómalos como elipsoides $\mathcal{D}$ paramétricos no processo de inversão estocástica, extrai-se o rácio geométrico de aspeto (*aspect ratio* - $\mathcal{AR}$): $\mathcal{AR} = \frac{\lambda_{\min}}{\lambda_{\max}}$ Onde $\lambda_{\min}$ representa o raio do eixo mais curto (espessura) e $\lambda_{\max}$ o raio do eixo mais longo (extensão lateral) do elipsoide ajustado. A distribuição de probabilidade de $\mathcal{AR}$ obtida para um determinado

alvo é formalmente comparada com os histogramas empíricos globais de depósitos conhecidos através de métricas de distância estatística, tais como a Divergência de Kullback-Leibler (D_{KL}):

$$D_{\mathrm{KL}}(P_{\text{alvo}} \parallel P_{\text{depósito}}) = \int P_{\text{alvo}}(x) \log\left(\frac{P_{\text{alvo}}(x)}{P_{\text{depósito}}(x)}\right) dx$$

[Distribuição do Rácio Geométrico $AR = \lambda_{\min} / \lambda_{\max}$]	
Interferência Sedimentar	Alvo
Económico	
(Grafite/Pirrotite: "Pancakes")	(Sulfureto
Magmático: "Blobby")	
Geometria Planar / Laminar Fina	Geometria
Tridimensional Achatada	
($AR \rightarrow 0.01 - 0.05$)	/ Compacta ($AR \rightarrow$
$0.20 - 0.60$)	
D_{KL} Elevada em Relação a Jazigos	D_{KL} Reduzida;
Elevada Sobreposição	
[DESCARTAR / DESPRIORIZAR]	[PRIORIZAR
PERFURAÇÃO]	

Tipo de Condutor, Condutividade Relativa, Geometria Típica ($AR = \lambda_{\min} / \lambda_{\max}$), Ação Estratégica Baseada em D_{KL}

Sulfureto Magmático (Alvo Ni-Cu-PGE), Elevada (até $10^9 \times$ a encaixante), "Compacta / Tridimensional / Lenticular ($AR > 0,15$)", Priorizar: Agendar perfuração profunda e acompanhamento de alta resolução.

Grafite Sedimentar (Interferente), Elevada ($10^6 - 10^9 \times$), "Laminar / Extensa / Espessura reduzida ($AR < 0,05$)", Descartar: Desconformidade morfológica com o histograma de depósitos económicos.

Pirrotite Sedimentar (Interferente), Moderada a Elevada, "Tabular / Acamada e contínua ao longo de km ($AR < 0,08$)", Despriorizar: Assinatura geométrica compatível com folhelhos piripáticos sedimentares.

2.3 Inversão Gravimétrica Probabilística em Sistemas Sedimentares de Cobre

A aplicação de métodos gravimétricos na prospeção de depósitos de cobre alojados em sedimentos — exemplificada pelo caso de estudo do projeto Mingomba (Zâmbia) — baseia-se na medição do campo de aceleração gravítica à superfície para mapear variações de densidade no subsolo. O sistema geológico de Mingomba é caracterizado por um contraste crítico de densidade: o embasamento alterado e os sedimentos superiores possuem densidades mais elevadas ($\rho \approx 2,70 - 2,85 \text{ g/cm}^3$), enquanto o aquífero poroso (a unidade estratigráfica crítica por onde fluíram as salouras mineralizantes de cobre) apresenta uma densidade significativamente menor ($\rho \approx 2,45 - 2,55 \text{ g/cm}^3$). A inversão determinística tradicional baseada em voxels (píxeis tridimensionais discretos) falha dramaticamente neste ambiente. Devido à penalização de

suavização L_2 , o algoritmo espalha o contraste de densidade por uma vasta amplitude vertical. Em troços onde a espessura real do aquífero é de apenas ≈ 300 metros, a inversão determinística estima uma espessura irrealista de ≈ 4.000 metros (um erro superior a 1.200%), gerando 5 anomalias falsas de espessamento ao longo do perfil que sugeririam 5 furos de sondagem independentes. A abordagem probabilística desenvolvida pela KoBold Metals resolve este problema ao substituir a grelha de voxels livres por uma **modelação probabilística de superfícies explícitas**. As fronteiras entre as unidades sedimentares são definidas como superfícies estocásticas parametrizadas, impondo-se uma estrutura de covariância espacial C_{ij} restrita ao pacote sedimentar: $C_{ij} = \sigma^2 \exp(-\frac{h_{ij}}{\theta})$. Onde h_{ij} é a distância espacial entre os pontos i e j dentro da mesma unidade litológica, σ^2 é a variância do contraste de densidade e θ é o comprimento de correlação espacial do pacote sedimentar.

A) Inversão Determinística (Voxels Suavizados):

Superfície $\rightarrow$ [ZONA SUAVIZADA / ESPESSURA ESTIMADA: 4.000 M]
 $\rightarrow$ 5 Alvos Falsos
 (Densidade diluída continuamente por penalização L_2)

B) Modelação Probabilística de Superfícies Explícitas:

Superfície $\rightarrow$ [CAMADA DEFINIDA / ESPESSURA ESTIMADA: ~ 300 M]
 $\rightarrow$ 1 Alvo Real
 (Covariância estocástica C_{ij} restrita ao pacote sedimentar)

Análise Comparativa de Desempenho: Caso de Estudo Mingomba (Gravimetria)

- **Espessura Real do Aquífero (Ground Truth de Sondagem):** ≈ 300 metros
- **Estimativa por Inversão Determinística baseada em Voxels :** ≈ 4.000 metros (Erro de sobrestimação $> 1.200\%$)
- **Alvos Falsos Sugeridos pelo Determinismo:** 5 locais de perfuração (Anomalias causadas por suavização vertical)
- **Estimativa por Modelação Probabilística de Superfícies Explícitas:** ≈ 300 metros (Com intervalo de incerteza $\pm 1\sigma$ ajustado aos dados)
- **Alvos Reais Isolados pela Modelação Probabilística:** 1 alvo de elevada precisão. A geração destes *ensembles* geofísicos probabilisticamente rigorosos e geometricamente condicionados fornece a base quantitativa necessária para alimentar os motores de otimização estocástica e tomada de decisão sequencial na escolha de alvos de perfuração.

3. Otimização de Campanhas de Perfuração e Decisão Sequencial Guiada por IA

A prospeção mineral opera historicamente sob uma ineficiência profunda: a taxa média da indústria extrativa situa-se em centenas de furos de sondagem por cada descoberta económica efetuada. Em contraste, a indústria do petróleo e gás (P&G) atinge taxas da ordem dos 3 furos por descoberta, fruto da adoção precoce de métodos probabilísticos e da sísmica de reflexão tridimensional. A integração de agentes de IA na prospeção mineral visa aproximar a eficiência da mineração aos padrões de P&G,

transformando a perfuração de um processo heurístico num processo quantitativo de maximização da aprendizagem por metro perfurado.

3.1 Mapeamento de Confiança: O Indicador Sinal-Ruído (Signal-to-Noise Ratio)

A quantificação do risco geológico e a validação do modelo espacial em qualquer ponto $\mathbf{x}$ do subsolo são traduzidas pelo campo escalar do Rácio Sinal-Ruído ($\text{SNR}(\mathbf{x})$), definido matematicamente como: $\text{SNR}(\mathbf{x}) = \frac{E[\theta(\mathbf{x})]}{\sigma(\theta(\mathbf{x}))}$. Onde $E[\theta(\mathbf{x})]$ representa o valor esperado (média da distribuição *a posteriori*) do parâmetro geológico/geofísico θ na coordenada $\mathbf{x}$, e $\sigma(\theta(\mathbf{x}))$ representa o desvio padrão (incerteza residual) do mesmo parâmetro no *ensemble* de realizações.


Interpretação Cartográfica da Confiança e Incerteza do Modelo

- **Elevado $\text{SNR}(\mathbf{x})$ ($\text{SNR} \gg 1$)**: Regiões onde o valor esperado do parâmetro domina a variabilidade residual do *ensemble*. O modelo possui elevada confiança preditiva (ex.: zonas contíguas a furos de sondagem existentes em que a geometria da camada mineralizada está bem delimitada).
- **Baixo $\text{SNR}(\mathbf{x})$ ($\text{SNR} \leq 1$)**: Regiões onde a incerteza do modelo (σ) é igual ou superior ao valor médio previsto. Indicam zonas de elevada incerteza epistémica, lacunas de informação espacial ou potenciais zonas de "alucinação" de modelos determinísticos, identificando rigorosamente onde a amostragem física é necessária.

3.2 Redução Eficiente de Incerteza e Seleção de Alvos "50/50"

A seleção tradicional do local de perfuração padece frequentemente de vieses organizacionais e financeiros. Destacam-se a **"perfuração para relações públicas/angariação de fundos"** (executada em locais onde se sabe previamente existir minério de alto teor para confirmar dados conhecidos e gerar comunicados de imprensa positivos) e a **"perfuração em zonas comprovadamente estéreis"**. Ambos os cenários apresentam um **Eficácia da Informação** (*Efficacy of Information*) nula. A Eficácia da Informação (ΔH) é formalizada através do Ganho de Informação Esperado ou Redução da Entropia de Shannon sobre a distribuição de probabilidade conjunta de todo o depósito mineral $\mathbf{m}$: $\Delta H = H(P(\mathbf{m})) - E[d_{\text{furo}} | P(\mathbf{m}, d_{\text{furo}})]$. Onde $H(P(\mathbf{m}))$ é a entropia inicial da distribuição do modelo e $E[d_{\text{furo}} | P(\mathbf{m}, d_{\text{furo}})]$ é a entropia esperada após a assimilação dos novos dados obtidos pelo futuro furo de sondagem d_{furo} . Para maximizar ΔH , o agente de decisão adota a heurística do **alvo "50/50"**: posicionar o furo de sondagem no ponto espacial de incerteza máxima do sistema, onde a probabilidade *a priori* de interceptar a camada mineralizada é de 50%.

[Matriz de Decisão de Perfuração e Aprendizagem]	
Certeza de Minério	Incerteza Máxima
Certeza de Estéril	
(Teor Elevado Conhecido)	(Alvo "50/50")
(Ausência Confirmada)	



Regras de Decisão para a Seleção Otimizada de Alvos de Perfuração


1. **Regra de Eliminação do Viés de Confirmação (PR):** É estritamente proibido alocar capital de perfuração em blocos onde a presença de teor económico já possui um valor de $\text{SNR} \gg 3$, visto que a informação adicional obtida (ΔH) é assintoticamente nula.
2. **Regra de Eliminação do Desperdício Estéril:** É estritamente proibido perfurar em zonas onde os dados geofísicos e geológicos confirmam com elevada probabilidade a ausência do aquífero ou condutor ($\text{SNR} \rightarrow 0$ com média estéril).
3. **Regra do Limiar de Incerteza Máxima (Heurística 50/50):** Os furos de sondagem devem ser cravados nas superfícies de fronteira onde a probabilidade de presença do corpo mineralizado é de $P(\text{minério}) \approx 0,5$, onde a variação estocástica do *ensemble* é máxima.
4. **Regra de Minimização da Variância Global:** O local ótimo para o próximo furo é aquele que maximiza a redução da variância estocástica integrada sobre todo o volume do projeto e não apenas na vizinhança imediata do furo.


3.3 Formulação do Problema de Perfuração como uma Árvore de Decisão Sequencial (Xadrez/Go)

A definição de uma campanha de exploração profunda não deve ser tratada como a escolha estática e isolada do "próximo furo", mas sim como um **Problema de Decisão Sequencial sob Incerteza** em árvores de decisão altamente ramificadas. Este processo é formalmente modelado como um Processo de Decisão de Markov Parcialmente Observável (POMDP) e resolvido via algoritmos de Pesquisa em Árvore de Monte Carlo (*Monte Carlo Tree Search* - MCTS). Análogo ao planeamento de jogadas em Xadrez ou Go, a IA não avalia apenas a consequência imediata do Furo K , mas sim as ramificações de informação desencadeadas até N passos à frente ($K+1, K+2, \dots, K+N$). Cada resultado hipotético de um furo altera a distribuição *a posteriori* do modelo, abrindo novos ramos de decisão na árvore de exploração.

[Árvore de Decisão Sequencial MCTS / POMDP]

(Estado Atual H_0)





O agente de IA simula milhares de trajetórias de perfuração na árvore MCTS, selecionando a sequência de posições que maximiza a probabilidade acumulada de delimitação do jazigo ao menor custo financeiro total. | Eixo de Decisão | Estratégia Tradicional de Perfuração (Heurística/PR) | Estratégia do Agente de IA Sequencial (MCTS / POMDP) || ----- | ----- | ----- || **Visão Operacional** | Míope; avalia o sucesso de forma isolada no próximo furo ($\$1\text{passo}\$$). | Sistémica e Estocástica; calcula a sequência ótima para a campanha ($\$N\text{passos à frente}\$$). || **Métrica de Seleção** | Intuição visual de mapas $\$2\mathrm{D}\$$ ou alinhamento com perspectivas de financiamento de curto prazo. | Maximização do Ganho de Informação Esperado (ΔH) sobre o modelo conjunto $\$3\mathrm{D}\$$. || **Gestão da Incerteza** | Reativa; ajusta a localização dos furos pontualmente após cada resultado de laboratório. | Proativa; antecipa todos os ramos futuros de incerteza através da simulação do *ensemble* . || **Eficiência de Descoberta** | Baixa; requer historicamente centenas de furos de sondagem por descoberta profunda. | Elevada; otimizada matematicamente para aproximar a taxa de sucesso aos padrões de P&G ($\sim 3\text{furos/descoberta}\$$). |

A otimização sequencial das campanhas de perfuração alimenta continuamente o modelo probabilístico. A incerteza quantificada e preservada neste *ensemble* deve ser propagada sem filtros de conversão até às etapas finais de engenharia mineira e planeamento operacional.

4. Integração Apoiada em Aprendizagem Automática no Planeamento Mineiro (Downstream Integration)

O valor económico e técnico da inversão geofísica probabilística é severamente comprometido se o *ensemble* de modelos — contendo a quantificação rigorosa do risco geológico — for comprimido numa média determinística única ao ser transferido para a engenharia de minas. A preservação da distribuição probabilística completa até às fases de

design da lavra, avaliação de reservas e operações subterrâneas é essencial para evitar falhas operacionais catastróficas e desvios orçamentais no arranque da exploração.

4.1 Propagação da Incerteza para as Curvas de Teor-Tonelagem e Planos de Lavra

Na prática tradicional de avaliação de jazigos, a estimativa de recursos apresenta uma única curva determinística de Teor-Tonelagem (*Grade-Tonnage Curve*). O desastre económico de muitos empreendimentos mineiros ocorre quando a lavra efetiva revela que os teores reais e as tonelagens recuperáveis se situam fora das previsões estáticas iniciais. A propagação direta do *ensemble* de realizações geológicas probabilísticas ($N > 1.000$ grelhas estocásticas) gera **bandas de incerteza explícitas** ($\pm 1\sigma, \pm 2\sigma$) em redor das curvas de Teor-Tonelagem . Esta representação probabilística permite à gestão executiva e aos engenheiros de minas tomar decisões de investimento orientadas pelo risco e definir limites de corte (*cut-off grades*) robustos em cenários P10, P50 e P90 (onde P10 representa o cenário conservador e P90 o otimista).

```
[Distribuições a Posteriori / Ensemble]
├─ Teor de Cobre (Cu Grade)
├─ Densidade Mássica (Bulk Density) → [Motor de Agregação
Estocástica / AI Filter] → [Curvas de Teor-Tonelagem
P10/P50/P90]
├─ Óxidos de Cobre (Met. Recovery) (Redução de
Dimensionalidade & Priorização) → [Design de Lavra
Subterrânea Otimizado]
└─ Qualidade da Rocha (RQD)
```


Parâmetros Críticos com Quantificação de Incerteza Propagada

- **Teor de Cobre (Copper Grade):** Distribuição de frequências e variabilidade espacial dos teores no espaço $\mathcal{D}$, definindo a probabilidade de contaminação por estéril (*dilution*) e a perda de minério (*ore loss*).
- **Densidade Mássica da Rocha (Bulk Density):** Intervalos de variação estocástica da densidade em cada bloco da mina, essenciais para o cálculo rigoroso da tonelagem total de rocha a ser desmantelada, transportada e processada.
- **Proporção de Óxidos de Cobre (Copper Oxides vs. Sulfides):** Mapeamento estocástico da transição entre mineralização oxidada (que requer lixiviação) e mineralização sulfetada (que exige flotação), impactando diretamente as taxas de recuperação metalúrgica e os custos de reagentes na fábrica.
- **Designação da Qualidade da Rocha (RQD - Rock Quality Designation):** Variação probabilística do grau de fraturamento e resistência da massa rochosa, determinando os requisitos de suporte geotécnico nas escavações subterrâneas.

4.2 Processamento de Ensembles Através de Ferramentas de Priorização e Operações Mineiras

A integração a jusante de milhares de realizações geológicas coloca um desafio computacional crítico: os *softwares* clássicos de planeamento e design de minas (como Surpac, Datamine ou Micromine) foram arquitetados na década de 1980 para importar um **único modelo de blocos determinístico** . Quando confrontados com um *ensemble* de $N > 1.000$ grelhas estocásticas de alta resolução, estes sistemas entram em colapso

computacional por incapacidade de processar o volume de dados. Para resolver este estrangulamento metodológico no projeto Mingomba, foram desenvolvidas **ferramentas internas de Inteligência Artificial para agregação estocástica e filtragem probabilística de dados**. Estas ferramentas funcionam como um motor intermediário de redução de dimensionalidade: absorvem as milhares de realizações do *ensemble*, filtram as variáveis geotécnicas e operacionais críticas através de funções de penalização de risco, e derivam um conjunto otimizado de restrições de fronteira probabilísticas que são subsequentemente inseridas nos algoritmos clássicos de design de minas e infraestruturas.



Variável Subsuperficial Predita, Impacto Direto na Operação / Design Mineiro

Designação da Qualidade da Rocha (RQD), "Dimensionamento dos sistemas de suporte de terreno (pregagens, betão projetado) e estabilidade de cavernas e galerias."

Afluência de Água (Water Inflows), Modelação hidrogeológica do aquífero poroso para dimensionamento das estações de bombagem subterrâneas e prevenção de inundações.

Densidade Mássica da Rocha, "Dimensionamento da frota de transporte, estimativa do consumo de energia na moagem (comminution) e plano de produção."

"Geometria do Corpo, Descontinuidades e Mergulho (Dip)", "Seleção do método de lavra subterrânea (Sublevel Open Stopping , Block Caving), orientação das frentes de desmonte e estabilidade estrutural."

Cavidades / Vazios (Voids) / Falhas Tectónicas, "Prevenção de colapsos estruturais, planeamento de segurança do avanço de galerias e controlo de diluição geomecânica."

Este Manual de Metodologia estabelece as diretrizes técnicas e concetuais para a padronização da inversão geofísica probabilística e da aprendizagem automática na prospeção profunda. Ao substituir o determinismo simplista por uma abordagem rigorosa baseada em *ensembles*, a indústria de exploração adquire a capacidade de quantificar o risco, otimizar drasticamente a alocação de capital em perfurações e acelerar a descoberta dos jazigos de minerais críticos indispensáveis ao futuro tecnológico e energético global.